BDMI 大作业

计划

暂定题目

面向已知谱线假设的 quasar 吸收谱 LLM 后训练：局域 mask、连续谱标定与速度空间拟合决策

课程要求对应

- 准备约 1000 个样本的数据集
- 使用 LLaMA-Factory 对基础模型进行 SFT
- 使用 OpenRLHF / VeRL 对模型做强化学习后训练

核心思路

这个项目不把重点放在“做一个大而全的多模态 agent”，而是放在“把 LLM 本身后训练成一个会在已知谱线假设下做局域分析决策的领域模型”。

也就是说：

- 输入时已经给定 `line_id` 和系统红移 `z_sys`
- 工具根据 `line_id` 与 `z_sys` 从整条光谱自动切出目标线附近的局域窗口
- LLM 在局域窗口中完成分析 mask、连续谱锚点标定和拟合策略决策
- continuum fitting 和速度空间 line fitting 仍由传统工具执行

这样能更清楚地体现 post-train，而不是只做 agent workflow，也避免把任务定义成“纯靠线型猜谱线身份”

与参考文章的关系

参考文献：EGENT: AN AUTONOMOUS AGENT FOR EQUIVALENT WIDTH MEASUREMENT /Users/mac/Downloads/2512.01270v1.pdf

借鉴点：

- 采用保守路线，使用局域 continuum fitting 和传统拟合作为工具层
- 不让 LLM 直接替代物理拟合器

区别：

- 参考文章重点是 agent workflow 和自动测量流程
- 本项目重点是 post-train：构造领域数据集，通过 SFT + RL 训练 LLM 在 quasar 吸收谱任务中的结构化判读与决策能力
- 数据域也从文章中的恒星谱测量转向 quasar 吸收谱分析

任务定义

给定：

- `line_id`
- `z_sys`
- 整条 quasar 光谱的 `wavelength / flux / ivar / pipeline_mask`

系统先根据 `lambda_obs = lambda_rest * (1 + z_sys)` 自动截取目标线附近的局域谱窗，然后分两步完成分析。

第一步：局域连续谱准备

- LLM 在观测波长空间中读取局域谱窗
- 预测分析用 mask 区间
- 给出连续谱 anchor points

- 判断当前窗口是否需要扩展或缩小

第二步：速度空间拟合决策

- 工具利用第一步输出完成局域 continuum fitting
- 工具将归一化后的谱转到该条线的局域速度空间，并执行候选拟合
- LLM 读取拟合结果、残差和速度空间谱形，判断当前结果是否可信，以及下一步应执行 accept / refit / add_component / reject / inspect 中的哪一步

因此，LLM 的主任务不是直接完成物理拟合，而是：

- 在污染和不连续采样下做分析 mask
- 辅助局域连续谱标定
- 复核速度空间拟合
- 做结构化决策

任务范围

MVP 只做 2 类目标，避免任务过大：

- H I / DLA
- C IV doublet

可选扩展：

- N V
- O VI

原则上不做“任意元素识别”，只做固定谱线类型的结构化判读

输入与输出

系统级输入至少包括：

- `line_id`
- `z_sys`
- `wavelength`
- `flux`
- `ivar`
- `pipeline_mask`

说明：

- 不要求人工手动切局域窗口，由工具自动切
- 局域谱窗保留真实采样、断裂和 gap，不强行重采样成完全连续的序列
- `pipeline_mask` 用作硬 mask，LLM 额外预测分析用 mask

为了让任务足够具体，数据集可拆为两类样本。

子任务 A：局域 mask 与连续谱锚点预测
输入：

- `line_id`
- `z_sys`
- 该线局域观测波长窗口内的 `wavelength / flux / ivar / pipeline_mask`

输出 JSON 示例：

```
{
  "window_action": "keep",
  "analysis_mask_intervals_A": [[5578.2, 5584.6], [5601.1, 5603.0]],
  "continuum_anchor_points_A": [5568.0, 5572.5, 5594.0, 5608.0],
  "quality": "medium",
  "rationale": "Mask the sky residual and the deep absorption core before continuum
fitting."
}
```

子任务 B：速度空间拟合复核与动作选择
输入：

- `line_id`
- `z_sys`
- 归一化后的速度空间谱
- 工具给出的候选拟合参数
- 残差统计与拟合质量摘要

输出 JSON 示例：

```
{
  "present": true,
  "fit_ok": false,
  "next_action": "add_component",
  "preferred_n_components": 2,
  "final_center_shift_kms": -38.0,
  "quality": "medium",
  "final_confidence": 0.78,
  "rationale": "The residual is asymmetric around line center, suggesting at least one
extra component."
}
```

数据集设计

数据来源暂定为 DESI quasar spectra 及其相关 catalog。

样本构造方式：

- 从已知 DLA / C IV catalog 中抽取目标窗口
- 从无目标吸收线区域抽取负样本窗口
- 从低 SNR、telluric 干扰、sky residual、gap、不连续采样、拟合失败样本中抽取 hard cases
- 对同一窗口保留不同阶段信息，分别构造成子任务 A 和子任务 B 的样本
- 对同一窗口生成不同质量的候选拟合结果，用于训练模型学习 accept / refit / add_component / reject

监督信号来源：

- `pipeline_mask`、坏点、gap、已知 sky/telluric 区段可直接作为硬 mask
- analysis mask 可由规则方法和少量人工校正共同生成
- continuum anchor points 可由高质量局域 continuum 拟合反推出参考锚点，或由少量人工标定补充
- 子任务 B 的动作标签和参数参考值可由传统拟合工具结果加人工 QC 生成

样本总量目标：

- 约 1000 到 1500 个局域窗口

- 每个窗口可生成 1 到 2 条训练记录，因此总训练记录数可高于 1000

数据划分：

- train / valid / test = 70 / 15 / 15

为什么不手工切光谱

不手工切窗口，统一由工具自动完成：

- 根据 `line_id` 和 `z_sys` 计算目标线的理论观测位置
- 再按固定速度宽度或波长宽度截取局域窗口
- 保留原始采样、断裂和 pipeline mask

这样切窗属于工具层和数据预处理，不属于人工标注工作

SFT 阶段

使用 LLaMA-Factory 对基础模型进行监督微调。

训练目标：

- 学会在局域观测波长空间里输出分析 mask 和 continuum anchor points
- 学会读取速度空间拟合结果并输出结构化决策
- 学会遵守固定 JSON schema
- 学会给出较保守、较少幻觉的结构化判断

基础模型暂定：

- 7B 或 8B 级别的开源模型

RL 阶段

使用 OpenRLHF / VeRL 继续训练，不先训练 reward model，而是优先采用规则可验证的 reward。

子任务 A 的奖励可包括：

- JSON 合法：+0.10
- analysis mask 与参考 mask 的 interval IoU / point-wise F1：+0.30
- anchor points 对 continuum 拟合误差的改善：+0.25
- window_action 正确：+0.10
- rationale 与输出一致：+0.05

子任务 B 的奖励可包括：

- JSON 合法：+0.10
- present 判断正确：+0.20
- fit_ok 判断正确：+0.15
- next_action 判断正确：+0.20
- preferred_n_components 正确：+0.10
- final_center_shift_kms 落在容差内：+0.15
- rationale 与结构化结论一致且不过度幻觉：+0.10

这样强化学习的目标不是“学会物理拟合”，而是“学会更稳健地做 mask、连续谱辅助标定和速度空间拟合决策”

评价指标

主指标：

- analysis mask 的 interval IoU 或 point-wise F1
- anchor points 驱动下的 continuum 拟合误差改善量
- present 的 F1 / precision / recall
- fit_ok 的 accuracy
- next_action 的 accuracy
- preferred_n_components 的 accuracy
- center shift 的 MAE 或容差命中率
- JSON 合法率

辅助指标：

- 报告文本的事实一致性
- 在 hard cases 上的表现
- Base → SFT → RL 三个阶段的对比提升

Baseline 与对比

需要至少比较三种模型：

- Base model
- SFT model
- SFT + RL model

还可以加入：

- 只用规则方法生成 mask 和 anchor 的工具基线
- 不带拟合结果摘要的 LLM 输入版本
- 不带 `line_id` 或不带 `z_sys` 的退化输入版本

通过这些对比说明：

- post-train 是否真的提升了局域谱线分析决策能力
- RL 是否真的改善了动作决策和输出稳定性
- LLM 是否真的利用了谱线先验和速度空间信息

可行性判断

这个方案比“整谱多模态 agent”更保守，但更贴合课程要求，也比“纯看线型猜谱线身份”更物理合理。

优点：

- 任务边界清楚，输入中已经给定 `line_id` 与 `z_sys`
- 数据集容易程序化构造，且容易达到 1000 个样本以上
- SFT 和 RL 都有明确训练目标
- 评价指标可程序化计算
- 与参考文章有联系，但又能突出 post-train 贡献

风险：

- 如果输入表示设计得太原始，LLM 可能学不到有效光谱模式
- 如果 anchor points 和 mask 的标注质量不稳定，训练信号会偏噪
- 如果样本过于简单，RL 的提升可能不明显
- 因此需要在样本构造时加入足够多的 hard cases

最小可交付版本

最小版本只要求完成：

- H I / DLA 与 C IV 的局域窗口自动切取
- 子任务 A：analysis mask 与 continuum anchor points 预测
- 子任务 B：速度空间拟合复核与动作选择
- LLaMA-Factory SFT
- OpenRLHF / VeRL 的规则奖励 RL
- Base / SFT / RL 三阶段评测对比

如果时间允许，再加入：

- N V 或 O VI
- 更复杂的多成分拟合决策
- 小图辅助输入